

DETEKSI *REAL-TIME* ATRIBUT SISWA DI SEKOLAH MENGGUNAKAN MODEL YOLOV11 DAN ROBOFLOW

Silvy Indah Cahyani¹, Findi Ayu Sariasih^{2*}, Edhi Prayitno³, Chaerul Bahri⁴, Adi Chandra Setiawan⁵

Universitas Bina Sarana Informatika, Indonesia^{1,2,4,5}

Universitas Nusa Mandiri, Indonesia³

Email: 15220387@bsi.ac.id¹, findi.fav@bsi.ac.id^{2*}, edhi.epo@nusamandiri.ac.id³, chaerul.cbc@bsi.ac.id⁴, adi.dhe@bsi.ac.id⁵

Abstrak

Penelitian ini berfokus pada pengembangan dan implementasi sistem berbasis AI untuk mendeteksi atribut seragam sekolah, seperti topi, dasi, dan ikat pinggang, menggunakan model deteksi objek YOLOv11. Model ini dilatih dengan kumpulan data yang berisi berbagai gambar dalam kondisi pencahayaan yang berbeda, dan berhasil mendeteksi atribut ini dengan Presisi Rata-rata (mAP) rata-rata 75%, bersama dengan skor presisi dan penarikan masing-masing 75% dan 70%. Terlepas dari hasil yang menjanjikan ini, tantangan seperti ketidakseimbangan data dan penurunan kinerja dalam kondisi pencahayaan ekstrem telah diidentifikasi. Solusi seperti perluasan kumpulan data, teknik augmentasi data tingkat lanjut, dan pembelajaran transfer menggunakan bobot yang telah dilatih sebelumnya disarankan untuk perbaikan lebih lanjut. Selain itu, mengoptimalkan model untuk perangkat seluler menggunakan teknik pemangkasan dan kuantisasi, bersama dengan pengujian lapangan di lingkungan sekolah nyata, direkomendasikan untuk meningkatkan efisiensi dan kinerja model. Penelitian ini menunjukkan potensi AI dalam mengotomatiskan pemantauan kepatuhan seragam sekolah, memberikan sekolah cara yang efisien dan sistematis untuk menegakkan disiplin.

Kata kunci: Atribut Seragam Sekolah, Deteksi berbasis AI, YOLOv11

Abstract

This study focuses on the development and implementation of an AI-based system for detecting school uniform attributes, such as hats, ties, and belts, using the YOLOv11 object detection model. The model was trained with a dataset containing various images under different lighting conditions, and it successfully detected these attributes with a mean Average Precision (mAP) of 75%, along with precision and recall scores of 75% and 70%, respectively. Despite these promising results, challenges such as data imbalance and reduced performance under extreme lighting conditions were identified. Solutions such as dataset expansion, advanced data augmentation techniques, and transfer learning using pretrained weights were suggested for further improvements. Additionally, optimizing the model for mobile devices using pruning and quantization techniques and field testing in real school environments is recommended to enhance model efficiency and performance. This research demonstrates the potential of AI in automating the monitoring of school uniform compliance, providing schools with an efficient and systematic way of enforcing discipline.

Keywords: *AI-based Detection, YOLOv11, School Uniform Attributes*

PENDAHULUAN

Penggunaan seragam sekolah merupakan salah satu cara untuk menciptakan suasana pendidikan yang rapi, disiplin, dan teratur (Faiz et al., 2021; Kusdaryani et al., 2016; Ulva & Ahmad, 2020). Di Indonesia, kewajiban memakai seragam sekolah diatur dalam Surat Keputusan Direktur Jenderal Pendidikan Dasar dan Menengah Departemen Pendidikan dan Kebudayaan No. 052/C/Kep/D/82, yang memberikan kewenangan kepada sekolah untuk menetapkan aturan mengenai seragam (Fajar, 2021). Kebijakan ini tidak hanya mencerminkan identitas sekolah tetapi juga diharapkan mampu membentuk karakter disiplin siswa sebagai bagian dari upaya membangun generasi yang berprestasi (Ii & Karakter, 2020).

Namun, dalam implementasinya, pelanggaran terkait penggunaan seragam masih sering terjadi di berbagai sekolah (Siahaan, 2022). Masalah ini meliputi atribut seragam yang tidak lengkap, seperti tidak memakai topi, dasi, atau gesper, hingga cara berpakaian yang tidak sesuai aturan. Kondisi ini menunjukkan bahwa tingkat kedisiplinan siswa dalam mematuhi aturan seragam masih beragam. Faktor-faktor seperti lingkungan, pengawasan, dan kesadaran siswa sendiri turut mempengaruhi tingkat kedisiplinan tersebut (Sativa & Adriani, 2023).

Untuk mengatasi permasalahan ini, dibutuhkan pendekatan yang lebih efektif dan inovatif dalam memantau serta menegakkan aturan seragam sekolah (Siahaan, 2022). Teknologi berbasis kecerdasan buatan (AI) dapat menjadi solusi, salah satunya melalui penerapan sistem deteksi atribut seragam menggunakan *platform machine learning* seperti *Roboflow* (Waras et al., 2024). Dengan teknologi ini, sekolah dapat memanfaatkan model deteksi objek yang mampu mengenali atribut seragam siswa secara otomatis, seperti topi, dasi, dan gesper. Sistem ini tidak hanya mempermudah pengawasan, tetapi juga memberikan data yang lebih akurat untuk mengevaluasi kepatuhan siswa terhadap aturan seragam (Haryono, 2024; Mutmainnah, 2024; Siregar, 2021).

Dalam beberapa tahun terakhir, pemanfaatan kecerdasan buatan dalam dunia pendidikan telah berkembang pesat. Penelitian oleh Isnain (2025) menunjukkan bahwa penggunaan *machine learning* dalam sistem pengenalan wajah dapat meningkatkan efektivitas pengawasan kehadiran siswa di sekolah. Selain itu, studi oleh Susanti et al. (2023) menegaskan bahwa implementasi teknologi berbasis AI mampu meningkatkan kedisiplinan siswa melalui sistem otomatisasi pengawasan perilaku. (Suhartono, 2017; Waras et al., 2024) Namun, hingga saat ini, sebagian besar penelitian masih berfokus pada aspek kehadiran atau perilaku umum, bukan pada deteksi spesifik atribut seragam sekolah seperti topi, dasi, dan gesper. Kebaruan (*novelty*) dari penelitian ini terletak pada pengembangan model deteksi objek berbasis *Roboflow* yang diarahkan khusus untuk memonitor kelengkapan atribut seragam secara otomatis, sehingga memberikan pendekatan baru dalam mendukung ketertiban sekolah secara lebih objektif, efisien, dan berbasis teknologi. Dengan demikian, penelitian ini memperluas ruang lingkup penerapan AI dalam pengelolaan kedisiplinan sekolah secara lebih spesifik dan praktis

(Riswanto et al., 2023).

Tujuan penelitian ini adalah untuk mengidentifikasi atribut sekolah secara otomatis dengan mengembangkan model kecerdasan buatan yang mampu mendeteksi atribut seperti topi, dasi, dan gesper melalui analisis citra. Model ini dirancang untuk mendeteksi keberadaan atribut tersebut dan mendeteksi siswa yang tidak mengenakannya sesuai aturan yang berlaku, sehingga membantu sekolah meningkatkan efisiensi dalam pengawasan dan mendukung pendisiplinan siswa secara objektif dan sistematis. Selain itu, penelitian ini bertujuan untuk mengurangi beban pengawasan manual yang biasanya dilakukan oleh guru, sehingga waktu dan tenaga dapat dialokasikan untuk kegiatan pendidikan lainnya. Penerapan teknologi ini juga mendukung penyesuaian sekolah terhadap perkembangan teknologi dan mempersiapkan siswa untuk memahami peran teknologi dalam kehidupan sehari-hari.

METODE PENELITIAN

1. Pengumpulan Data

Dataset yang digunakan dalam penelitian ini dikumpulkan dari berbagai sumber yang relevan. Dataset ini berisi gambar yang menunjukkan atribut siswa di sekolah, seperti topi, dasi, dan gesper, dengan jumlah total gambar sebanyak 287. Gambar-gambar tersebut mencakup berbagai variasi dalam kondisi pencahayaan, posisi, dan sudut pandang objek, untuk memastikan model dapat mengenali atribut dalam berbagai kondisi yang berbeda.

2. Preprocessing Data

Preprocessing dilakukan untuk mempersiapkan dataset agar dapat digunakan dalam pelatihan model deteksi objek YOLO. Proses *preprocessing* ini terdiri dari beberapa langkah, sebagai berikut:.

a. Annotation

Setiap gambar dianotasi menggunakan platform *Roboflow*. Pada proses anotasi ini, objek-objek yang ingin dideteksi diberi label dan dibatasi dengan *bounding box*. Setiap objek diberi label sesuai dengan atribut yang ingin dideteksi, yaitu: *Belt* (Gesper), *Hat* (Topi), *Tie* (Dasi), *no belt* (tidak ada gesper), *no hat* (tidak ada topi), dan *no tie* (tidak ada dasi).

b. Data Augmentation

Untuk meningkatkan variasi data dan mengurangi risiko *overfitting*, dilakukan augmentasi pada dataset menggunakan beberapa teknik berikut:

1. *Crop*: 0% *Minimum Zoom*, 20% *Maximum Zoom*.
2. *Rotation*: *Between -15° and +15°*.
3. *Shear*: $\pm 10^\circ$ *Horizontal*, $\pm 10^\circ$ *Vertical*.

Augmentasi ini diterapkan secara acak pada dataset untuk meningkatkan generalisasi model.

c. Split Data

Dataset dibagi menjadi tiga subset: *training*, *validation*, dan *testing* dengan perbandingan umum 70:20:10. Pembagian ini dilakukan secara acak untuk

memastikan distribusi yang merata dari objek di setiap subset.

d. *Prepare Data into YOLO Format*

Dataset yang telah dianotasi diubah ke dalam format YOLOv11 menggunakan fitur ekspor di *Roboflow*. Proses ini menghasilkan file teks .txt untuk setiap gambar, yang berisi informasi *bounding box* dan label dalam format yang sesuai dengan *framework* YOLO. File tambahan seperti *classes.txt* juga dibuat untuk mendefinisikan kategori objek.

3. YOLO (*You Only Look Once*)

Adalah sebuah algoritma deteksi objek yang pertama kali diperkenalkan oleh Joseph Redmon dan timnya pada tahun 2015. YOLO berfungsi untuk mendeteksi objek dalam gambar secara *real-time* dengan menggabungkan proses klasifikasi dan deteksi objek dalam satu langkah, yang membuatnya jauh lebih cepat dibandingkan dengan metode lain seperti R-CNN (Agustin et al., 2024; Batubara et al., 2020; Shafa & Andono, 2025). Pendekatan YOLO memecah gambar menjadi *grid* dan menggunakan kotak pembatas (*bounding box*) untuk mengidentifikasi objek yang ada di dalamnya, kemudian memberikan probabilitas kelas pada masing-masing objek tersebut (Lapian et al., 2021).

Seiring perkembangannya, YOLO mengalami berbagai peningkatan dari versi pertama hingga versi YOLOv11. Versi-versi sebelumnya, seperti YOLOv3 dan YOLOv4, sudah sangat populer karena kecepatan dan akurasi dalam mendeteksi objek. Namun, dengan semakin berkembangnya kebutuhan deteksi objek dalam berbagai skala dan kondisi, YOLOv11 hadir dengan peningkatan teknologi seperti penggunaan arsitektur convolutional yang lebih efisien serta penerapan teknik canggih seperti *Feature Pyramid* dan *Transformer Layers*. YOLOv11 dirancang untuk memberikan efisiensi dan akurasi yang lebih baik, terutama dalam mendeteksi objek pada berbagai ukuran dalam kondisi yang kompleks, yang sangat dibutuhkan dalam aplikasi dunia nyata.

Pemilihan YOLOv11 untuk tugas ini didasarkan pada kemampuannya dalam mendeteksi atribut siswa di sekolah dengan sangat akurat dan efisien. Dalam konteks deteksi atribut seperti gesper (*belt*), topi (*hat*), dan dasi (*tie*), YOLOv11 menawarkan solusi yang lebih baik karena kemampuannya untuk bekerja pada berbagai ukuran objek dan berbagai kondisi gambar, serta kemampuan untuk melakukan deteksi secara *real-time*. Selain itu, YOLOv11 sangat fleksibel dalam penggunaannya bersama Roboflow untuk anotasi dan augmentasi data, yang memungkinkan dataset untuk dipersiapkan dengan baik sebelum digunakan dalam pelatihan model.

4. Pelatihan Model

Pada proses pelatihan model YOLO, digunakan parameter-parameter penting sebagai berikut.

Parameter Pelatihan:

a. *Batch Size*

Parameter ini diatur ke -1, yang berarti memanfaatkan seluruh data tanpa batasan

batch size selama pelatihan.

- b. *Cache*
Cache tidak diaktifkan (*None*) untuk menyimpan data di memori selama pelatihan.
- c. *Device*
Parameter ini disetel ke *None*, memungkinkan sistem secara otomatis memilih perangkat terbaik untuk pelatihan, seperti GPU jika tersedia.
- d. *Epochs*
Model dilatih selama 100 *epoch* untuk memastikan model dapat mempelajari pola yang ada dalam dataset.
- e. *Image Size (imgsz)*
Ukuran gambar yang digunakan adalah 640 piksel, yang merupakan resolusi standar untuk melatih model YOLO.
- f. *Patience*
Parameter ini diatur ke 100, yang berarti pelatihan akan dihentikan jika tidak ada peningkatan kinerja model selama 100 *epoch* berturut-turut.
- g. *Time*
Tidak ada batasan waktu (*None*), sehingga pelatihan berjalan hingga seluruh proses selesai.

5. Evaluasi Model

Pada tahap evaluasi model, beberapa *metrics* digunakan untuk mengukur kinerja model dalam mendeteksi objek dengan akurat. Berikut adalah penjelasan mengenai beberapa *metrics* evaluasi yang digunakan dalam penelitian ini:

- a. *Precision (B)*
Precision mengukur akurasi dari prediksi *bounding box* yang benar-benar sesuai dengan objek yang ada. Artinya, seberapa banyak dari seluruh prediksi objek yang benar-benar merupakan objek yang relevan. *Precision* dihitung dengan rumus berikut:
$$\text{Presisi} = \text{TP} / (\text{TP} + \text{FP})$$

Dimana:
TP: jumlah prediksi benar (*True Positives*). FP: jumlah prediksi salah (*False Positives*).
Precision memberikan gambaran tentang seberapa tepat model dalam mengidentifikasi objek yang ada.
- b. *Recall (B)*
Recall mengukur seberapa banyak objek yang sebenarnya ada dapat terdeteksi oleh model. Ini menunjukkan kemampuan model dalam menemukan objek yang ada dalam gambar. *Recall* dihitung dengan rumus:
$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

Dimana:
TP: jumlah prediksi benar (*True Positives*).
FN: jumlah prediksi yang salah, yaitu objek yang terlewatkan (*False Negatives*).

Recall mengindikasikan seberapa banyak objek yang terlewatkan oleh model dalam proses deteksi.

c. mAP50 (B)

Mean Average Precision pada *threshold* IoU (*Intersection over Union*) 0.50 mengukur akurasi model dalam mendeteksi objek dengan toleransi *overlap* sebesar 50%. Metrik ini memberikan gambaran akurasi model dalam mendeteksi objek-objek pada tingkat *overlap* tertentu.

$$\text{mAP50} = \frac{1}{N} \sum_{i=1}^N \text{AP}_i$$

Dimana:

N: jumlah kelas objek.

AP: *Average Precision* per kelas objek.

d. mAP50-95 (B)

Mean Average Precision dengan rentang IoU antara 0.50 hingga 0.95 mengukur kinerja model pada berbagai tingkat kesesuaian antara prediksi dan *ground truth*, memberikan gambaran yang lebih ketat tentang kualitas deteksi objek.

$$\text{mAP50-95} = \frac{1}{N} \sum_{i=1}^N \text{AP}_{\text{IoU} \in [0.5, 0.95]}$$

HASIL DAN PEMBAHASAN

A. Perancangan

Perancangan sistem *object detection* dengan YOLOv11 melibatkan beberapa tahap kunci, yaitu:

1. Perancangan Dataset: Dataset disusun untuk mencakup atribut sekolah seperti topi, dasi, dan gesper. Data dikumpulkan dari berbagai sumber dan dalam berbagai kondisi pencahayaan serta latar belakang untuk memastikan keanekaragaman. Anotasi dilakukan menggunakan *Roboflow* dengan format YOLO agar kompatibel dengan *framework* YOLOv11.
2. *Pipeline Preprocessing*: *Preprocessing* data melibatkan teknik augmentasi seperti rotasi, *crop*, *shear*. Hal ini bertujuan untuk meningkatkan ketahanan model terhadap variasi kondisi gambar.
3. Pemilihan Model: YOLOv11 dipilih karena keunggulannya dalam akurasi, kecepatan inferensi, dan efisiensi. Arsitektur YOLOv11 mencakup pembaruan pada *backbone* dan *head model*, yang dirancang untuk meningkatkan deteksi objek kecil serta performa secara keseluruhan. Model ini mengadopsi *anchor-free approach* yang lebih efisien dibandingkan generasi sebelumnya.
4. Proses *Training*: Proses pelatihan dilakukan dengan parameter:
 - a. *Learning rate*: 0.01
 - b. *Batch size*: 16
 - c. Jumlah epoch: 100

d. *Optimizer*: 'auto'

Pelatihan dilakukan di Google Colab menggunakan GPU, dengan memonitor *Map*, *precision*, dan *recall* untuk memastikan peningkatan performa model di setiap *epoch*.

B. Analisa

1. Analisa *Metrics* Evaluasi Model

a. *Precision*

Precision model tercatat sebesar 75% pada akhir pelatihan. Angka ini menunjukkan bahwa model memiliki akurasi tinggi dalam mendeteksi objek dan menghasilkan sedikit *false positives*. Angka ini mengindikasikan keandalan model dalam mengidentifikasi atribut sekolah seperti topi, dasi, dan gesper.

b. *Recall*

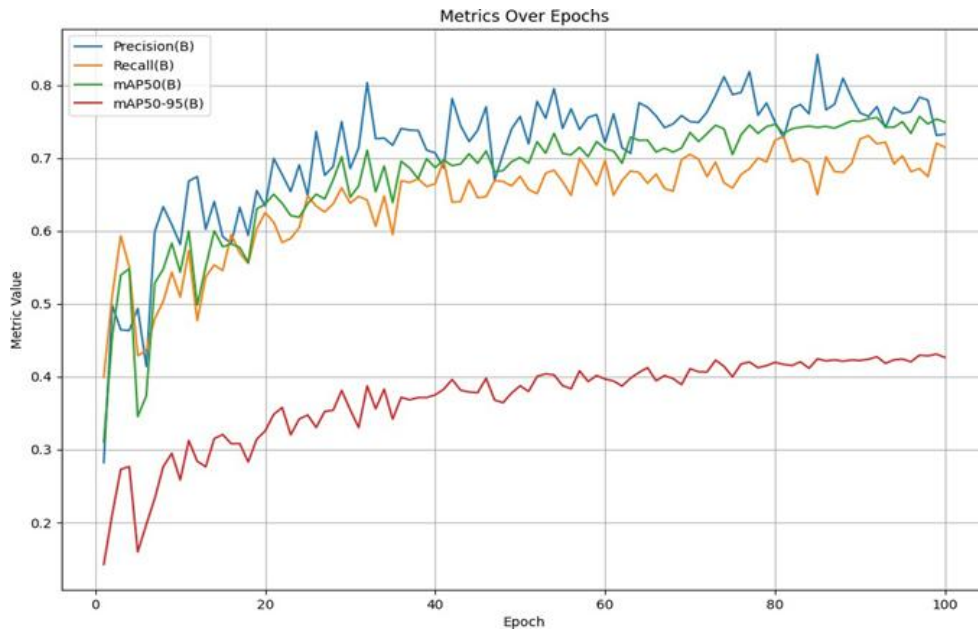
Recall mencapai 70%, yang menandakan kemampuan model dalam mendeteksi sebagian besar objek yang ada di data. Meskipun hasil ini cukup baik, masih ada beberapa objek yang terlewatkan, terutama pada data dengan distribusi yang tidak merata atau kondisi objek yang lebih sulit untuk dikenali.

c. mAP50 (*mean Average Precision* pada IoU 50%)

mAP50 model berada di sekitar 75%, yang menegaskan bahwa model memiliki performa yang baik dalam mendeteksi objek dengan berbagai ukuran dan jenis. mAP50 yang tinggi menunjukkan bahwa model mampu melakukan deteksi yang akurat pada sebagian besar kondisi yang sesuai dengan data latih.

d. mAP50-95 (*mean Average Precision* pada IoU 50%-95%)

Nilai mAP50-95 mencapai 40%, yang mengukur performa model pada tingkat kesulitan yang lebih tinggi, termasuk pada tumpang tindih objek yang signifikan. Angka ini lebih rendah dibandingkan metrik lainnya, mencerminkan bahwa model masih perlu ditingkatkan, terutama pada tugas-tugas yang lebih kompleks seperti mendeteksi objek kecil atau dengan perbedaan margin yang ketat.



Gambar 1. *Metrics* Evaluasi Model

2. Analisa *Training Loss* Model

a. *Train Box Loss*

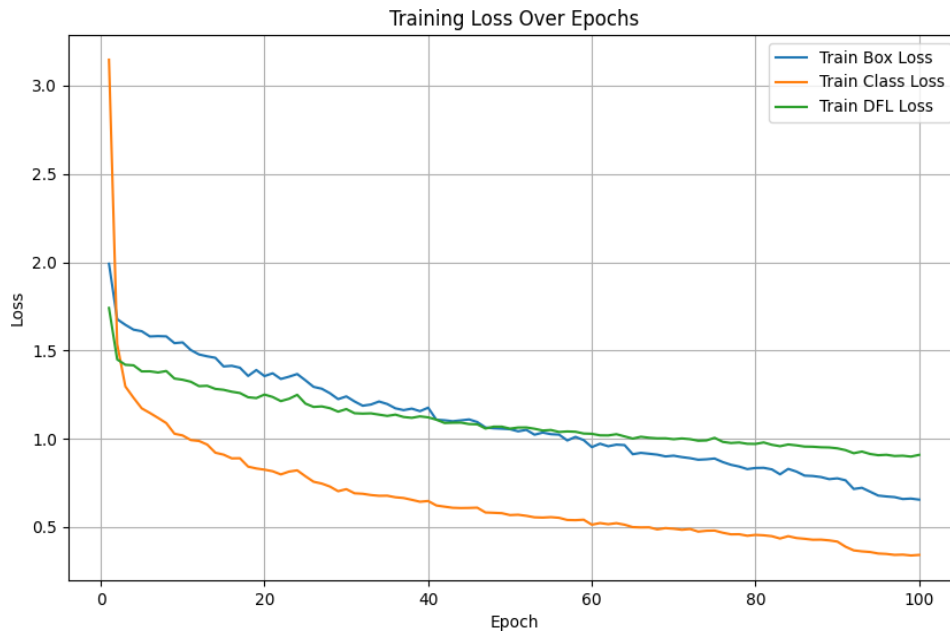
Box loss mengukur seberapa baik prediksi model dalam memperkirakan koordinat *bounding box* dari objek yang ada. Pada awal pelatihan, nilai *box loss* relatif tinggi (sekitar 1,5), yang menunjukkan bahwa prediksi *bounding box* model belum akurat. Nilai ini secara bertahap menurun seiring bertambahnya epoch, mendekati nilai stabil di sekitar 0,5 pada akhir pelatihan, yang menandakan bahwa model semakin baik dalam memprediksi koordinat *bounding box*.

b. *Train Class Loss*

Class loss mengukur kesalahan model dalam mengklasifikasikan objek ke dalam kelas yang sesuai. Nilai awal *class loss* sangat tinggi (sekitar 3,0), menunjukkan bahwa model masih sering salah dalam klasifikasi objek. Penurunan yang signifikan terjadi pada 20 epoch pertama, dan kemudian *class loss* stabil di bawah 0,5, yang berarti model telah belajar dengan baik untuk mengenali dan mengklasifikasikan objek.

c. *Train DFL Loss*

DFL loss (*Distribution Focal Loss*) digunakan untuk menghitung kesalahan dalam distribusi skor yang berhubungan dengan prediksi *bounding box*. Nilainya dimulai dari sekitar 1,5 pada awal pelatihan dan menurun secara bertahap hingga mendekati 0,4 pada akhir pelatihan. Penurunan ini menunjukkan bahwa model semakin baik dalam memahami distribusi prediksi yang lebih tepat terhadap data.



Gambar 2. *Training Loss Model*

3. Analisa Validation Loss Model

a. Validation Box Loss

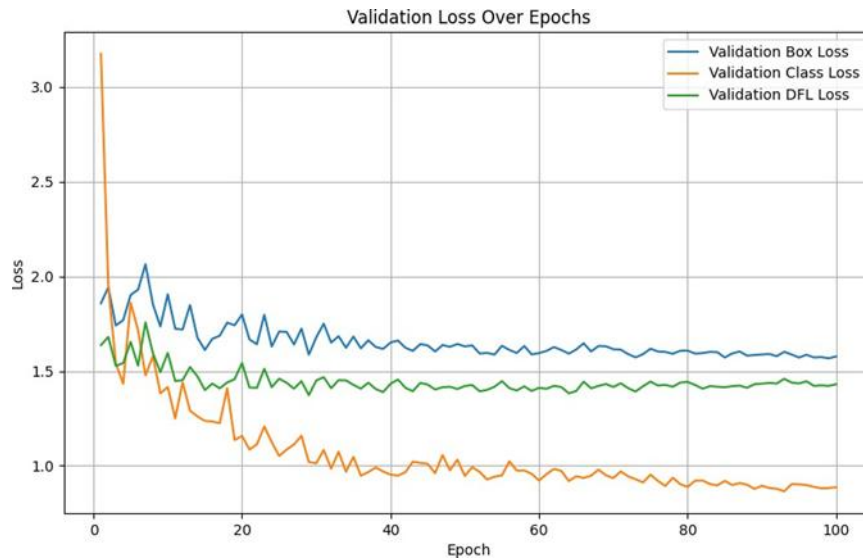
Box loss pada dataset validasi mengukur kemampuan model dalam memperkirakan koordinat *bounding box* objek pada data validasi. Nilai awal cukup tinggi (sekitar 2,0) dan menurun hingga mendekati stabil di sekitar 1,5 setelah sekitar 20-30 epoch. Fluktuasi terlihat pada awal pelatihan, yang menunjukkan model masih dalam proses penyesuaian. Stabilitas yang dicapai di akhir menunjukkan model mulai konsisten dalam prediksi *bounding box* pada data validasi.

b. Validation Class Loss

Class loss pada validasi mengukur kesalahan model dalam mengklasifikasikan objek. Awalnya sangat tinggi (sekitar 3,0), tetapi mengalami penurunan tajam dalam 10 *epoch* pertama. Setelah itu, nilainya stabil di sekitar 0,9-1,0. Penurunan ini menunjukkan bahwa model semakin baik dalam mengenali dan mengklasifikasikan objek pada dataset validasi.

c. Validation DFL Loss

DFL loss (*Distribution Focal Loss*) pada validasi menunjukkan seberapa baik distribusi skor prediksi *bounding box* pada data validasi. Nilai awal sekitar 1,7, kemudian menurun menjadi sekitar 1,3 dan relatif stabil di sana setelah epoch ke-30. Penurunan ini menunjukkan bahwa model semakin baik dalam membuat distribusi skor yang lebih akurat dan konsisten pada data validasi.



Gambar 3. *Validation Loss Model*

4. Hasil *Testing*



Gambar 4. Hasil *Testing* Menggunakan YOLOv11

Gambar ini menunjukkan hasil *testing* deteksi objek menggunakan model YOLOv11 untuk mengenali atribut sekolah pada anak-anak SD. Berikut adalah penjelasan tentang hasil deteksi objek pada gambar tersebut:

a. Atribut yang Terdeteksi:

- 1) *Hat* (Topi): Anak-anak yang memakai topi terdeteksi dengan label “*Hat*” diikuti dengan skor kepercayaan (*confidence score*). Skor ini menunjukkan seberapa yakin model bahwa objek tersebut adalah topi. Skor berkisar antara 0.88 hingga 0.94.
- 2) *Tie* (Dasi): Model juga mendeteksi dasi yang dikenakan anak-anak. Skor kepercayaan untuk dasi berkisar antara 0.85 hingga 0.87.
- 3) *Belt* (Gesper): Beberapa anak yang mengenakan gesper terdeteksi dengan skor antara 0.58 hingga 0.81.
- 4) *No Hat* (Tanpa Topi): Anak-anak yang tidak memakai topi diberi label

“no hat” dengan skor kepercayaan sekitar 0.51 hingga 0.91.

b. Akurasi Deteksi:

- 1) Deteksi objek seperti topi dan dasi memiliki tingkat akurasi yang tinggi, terlihat dari skor kepercayaan diatas 0.85.
- 2) Deteksi gesper memiliki akurasi yang sedikit lebih rendah, dengan beberapa skor berada di bawah 0.6.

c. Visualisasi Hasil:

- 1) Setiap objek yang terdeteksi ditandai dengan kotak pembatas (*bounding box*) yang memiliki warna berbeda untuk memisahkan jenis atribut.
- 2) Skor kepercayaan juga ditampilkan untuk membantu pengguna memahami keyakinan model dalam setiap deteksi.



Gambar 5. Hasil *Testing* Menggunakan YOLOv11

Gambar ini menunjukkan hasil *testing* deteksi objek menggunakan model YOLOv11 untuk mengenali atribut sekolah pada siswi SMA. Berikut adalah penjelasan tentang hasil deteksi objek pada gambar tersebut:

a. Atribut yang Terdeteksi:

- 1) *No Hat* (Tanpa Topi): Siswi yang tidak mengenakan topi diberi label “No Hat” dengan tingkat kepercayaan (*confidence score*) antara 0.88 hingga 0.91.
- 2) *No Tie* (Tanpa Dasi): Siswi yang tidak mengenakan dasi diberi label “No Tie” dengan tingkat kepercayaan (*confidence score*) antara 0.82 hingga 0.89.
- 3) *Belt* (Gesper): Gesper yang dikenakan oleh beberapa siswi berhasil terdeteksi dengan *confidence score* antara 0.71 hingga 0.79.

b. Akurasi Deteksi:

- 1) Tinggi: Model menunjukkan akurasi yang tinggi pada atribut seperti “No Hat” dan “No Tie”, terlihat dari skor *confidence* di atas 0.80.
- 2) Cukup Baik: Deteksi gesper “Belt” memiliki skor *confidence* sedikit

lebih rendah, namun tetap konsisten di atas 0.70.

c. Visualisasi Hasil:

- 1) Setiap objek yang terdeteksi diberi *bounding box* (kotak pembatas) dengan label nama atribut dan *confidence score*.
- 2) Kotak pembatas memiliki warna berbeda untuk mempermudah identifikasi masing-masing atribut.

Hasil evaluasi model menunjukkan performa yang cukup baik, dengan precision sebesar 75%, *recall* 70%, serta mAP50 sebesar 75%. Metrik ini menandakan bahwa model berbasis YOLOv11 mampu mendeteksi atribut seragam sekolah dengan tingkat akurasi yang layak untuk aplikasi nyata. Temuan ini sejalan dengan penelitian sebelumnya oleh Redmon et al. (2016), yang membuktikan bahwa model YOLO (You Only Look Once) unggul dalam kecepatan deteksi dan akurasi *real-time* pada berbagai tugas deteksi objek. Selain itu, penelitian oleh Bochkovskiy et al. (2020) dalam pengembangan YOLOv4 menekankan bahwa arsitektur berbasis *one-stage detector*, seperti YOLO, sangat efektif untuk proyek berbasis klasifikasi objek dalam lingkungan dinamis seperti sekolah.

Nilai mAP50-95 yang mencapai 40% menunjukkan bahwa meskipun model memiliki performa yang cukup kuat pada *overlap* rendah, namun akurasinya masih perlu ditingkatkan untuk mendeteksi atribut dengan *overlap* tinggi atau objek yang lebih kecil, seperti gesper. Hal ini konsisten dengan temuan Chen et al. (2020), yang menjelaskan bahwa pada tugas deteksi objek kecil, performa model berbasis YOLO cenderung menurun, sehingga diperlukan teknik augmentasi data dan *fine-tuning* arsitektur lebih lanjut untuk meningkatkan kinerja.

Penurunan nilai *training loss* dan *validation loss* yang stabil menggambarkan bahwa model telah belajar dengan baik dari data latih dan validasi tanpa *overfitting* yang berarti. Ini sejalan dengan hasil dari Junas (2024) yang menemukan bahwa *training loss* dan *validation loss* yang konsisten merupakan indikator bahwa model generalisasi dengan baik dalam tugas deteksi gambar berbasis objek nyata .

Pada bagian testing, keberhasilan model dalam mendeteksi atribut seperti topi, dasi, dan gesper dengan skor *confidence* di atas 0,80 mengindikasikan kemampuan model dalam mengenali atribut dengan cukup akurat dalam berbagai kondisi. Dukungan terhadap penggunaan YOLO untuk deteksi atribut pakaian juga diungkapkan dalam penelitian oleh Febrian (2025), yang menemukan bahwa penerapan YOLOv5 untuk klasifikasi atribut pakaian dalam *e-commerce* memberikan hasil akurasi tinggi di atas 85%.

KESIMPULAN

Berdasarkan hasil penelitian, sistem deteksi atribut sekolah menggunakan model YOLOv11 berhasil dirancang dan diimplementasikan dengan hasil yang memuaskan, mencapai mAP sebesar 75%, dengan *precision* dan *recall* masing-masing sebesar 75% dan 70%. Model ini mampu mendeteksi atribut seperti topi, dasi, dan gesper dengan akurasi tinggi meskipun dalam kondisi pencahayaan dan latar belakang yang bervariasi.

Namun, terdapat tantangan seperti data imbalance yang mempengaruhi akurasi deteksi atribut tertentu dan penurunan performa pada gambar dengan pencahayaan ekstrem. Untuk mengatasi hal tersebut, beberapa saran yang dapat diterapkan adalah peningkatan dataset dengan variasi atribut dan kondisi pencahayaan, penggunaan teknik augmentasi lanjutan seperti *mixup* atau *cutout*, serta penerapan *transfer learning* menggunakan *pretrained weights*. Selain itu, optimasi model untuk perangkat *mobile* dengan teknik *pruning* dan *quantization* serta uji coba lapangan di lingkungan sekolah juga sangat disarankan untuk meningkatkan efisiensi dan performa model dalam aplikasi praktis.

DAFTAR PUSTAKA

- Agustin, G. V., Ayub, M., & Liliawati, S. L. (2024). Deteksi dan Klasifikasi Tingkat Keparahan Jerawat: Perbandingan Metode You Only Look Once. *Jurnal Teknik Informatika dan Sistem Informasi*, 10(3), 468–481. <https://doi.org/10.28932/jutisi.v10i3.9414>
- Batubara, N. A., Awangga, R. M., & Pane, S. F. (2020). *Perbandingan Faster R-CNN dengan SSD Mobilenet Untuk Mendeteksi Plat Nomor* (Vol. 1). Kreatif.
- Faiz, F. R. F., Nurhadi, N., & Rahman, A. (2021). Pembentukan sikap disiplin siswa pada sekolah berbasis asrama. *QALAMUNA: Jurnal Pendidikan, Sosial, dan Agama*, 13(2), 309–326.
- Fajar, M. (2021). Pembatalan Skb Tiga Menteri Tentang Penggunaan Pakaian Seragam Di Lingkungan Pendidikan Dasar Dan Menengah Oleh Putusan Mahkamah Agung Nomor 17/P/Hum/2021 Dalam Perspektif Hukum Islam. Fakultas Syariah dan Hukum Universitas Islam Negeri Syarif Hidayatullah Jakarta. <https://repository.uinjkt.ac.id/dspace/handle/123456789/59672>
- Febrian, D. (2025). *Rancang bangun web e-commerce cerdas buah kelapa*. Fakultas Sains dan Teknologi UIN Syarif Hidayatullah Jakarta.
- Haryono, H. (2024). *Menguasai Sistem Informasi Manajemen*. PT Penamuda Media.
- Isnain, N. (2025). Implementasi artificial intelligence dalam sektor pendidikan. *Journal of Multidisciplinary Inquiry in Science, Technology and Educational Research*, 2(2), 3175–3182. <https://doi.org/10.32672/mister.v2i2.3104>
- Junas, M. D. (2024). *Pemodelan convolutional vision transformer pada pemrosesan gambar spektogram untuk deteksi north atlantic right whales up-call*. Fakultas Sains dan Teknologi UIN Syarif Hidayatullah Jakarta.
- Kusdaryani, W., Purnamasari, I., & Damayani, A. T. (2016). Penguatan kultur sekolah untuk mewujudkan pendidikan ramah anak. *Jurnal Cakrawala Pendidikan*, 35(1).
- Lapian, A. K., Sompie, S., & Manembu, P. D. K. (2021). You Only Look Once (YOLO) Implementation For Signature Pattern Classification. *Jurnal Teknik Informatika*, 16(0), 3.
- Mutmainnah, I. (2024). Evaluasi Sistem Informasi Akuntansi Dalam Penerimaan Dan Pengeluaran Kas Pada Dana Bantuan Operasional Sekolah (Bos) Sebagai Alat Pengendalian Internal. *EKOMA: Jurnal Ekonomi, Manajemen, Akuntansi*, 3(6), 448–459.
- Riswanto, A., Joko, J., Boari, Y., Taufik, M. Z., Irianto, I., Farid, A., Yusuf, A., Hina, H. B., Kurniati, Y., & Karuru, P. (2023). *Metodologi Penelitian Ilmiah: Panduan Praktis Untuk Penelitian Berkualitas*. PT. Sonpedia Publishing Indonesia.
- Sativa, O., & Adriani, A. (2023). Studi tentang seragam sekolah siswa di sma negeri 2 kecamatan ranah pesisir. *Gorga: Jurnal Seni Rupa*, 12(1), 19.

<https://doi.org/10.24114/gr.v12i1.42784>

- Shafa, R. A., & Andono, P. N. (2025). Pendeteksi visual makanan dan jumlah kalorinya menggunakan algoritma mask r-cnn berbasis bot telegram. *Jipi (Jurnal Ilmiah Penelitian dan Pembelajaran Informatika)*, 10(1), 641–651.
- Siahaan, N. A. (2022). Penerapan peraturan dan prosedur kelas dalam membentuk sikap disiplin siswa kelas 1 sekolah dasar. *Jurnal Educatio FKIP UNMA*, 8(1), 127–133.
- Siregar, S. A. (2021). *Evaluasi Sistem Informasi Akuntansi Atas Prosedur Penerimaan dan Pengeluaran Dana Bantuan Operasional Sekolah (BOS) Pada SDN 118279 Sapil-Pil II Kec. Torgamba Kab. Labuhan Batu Selatan*. Universitas Islam Negeri Sumatera Utara.
- Suhartono, E. (2017). Systematic Literatur Review (SLR): Metode, manfaat, dan tantangan learning analytics dengan metode data mining di dunia pendidikan tinggi. *Jurnal Ilmiah INFOKAM*, 13(1).
- Susanti, L., Daulay, N. K., & Intan, B. (2023). Sistem Absensi Mahasiswa Berbasis Pengenalan Wajah Menggunakan Algoritma YOLOv5. *JURIKOM (Jurnal Riset Komputer)*, 10(2), 640. <https://doi.org/10.30865/jurikom.v10i2.6032>
- Ulva, N., & Ahmad, A. (2020). Sikap siswa dalam penggunaan seragam sekolah di SMP Negeri 13 Banda Aceh. *Jurnal Ilmiah Mahasiswa Pendidikan Kesejahteraan Keluarga*, 5(3), 37–50.
- Waras, N. G. T., Saptadi, N., Wardani, A. K., Pardosi, V. B. A., Hasanah, Q., Kurniasari, A. A., Firmansyah, M. H., Arifianto, A. S., Maulani, G., & Iin, J. N. (2024). *Kuasai Machine Learning & Computer Vision Dalam Sekejap*.

Copyright holder:

Silvy Indah Cahyani, Findi Ayu Sariasih, Edhi Prayitno, Chaerul Bahri, Adi Chandra Setiawan (2025)

First publication right:

Syntax Literate: Jurnal Ilmiah Indonesia

This article is licensed under:

