

# Implementasi Algoritma YOLOv11 Dan Roboflow Untuk Deteksi Tingkat Kematangan Anggur Berbasis Web

Nofita Sary<sup>1</sup>, Hendra Handoko Syahputra Pasaribu<sup>2\*</sup>, Rahel Juliana Situmeang<sup>3</sup>, Rizky Darmawan Darus<sup>4</sup>

<sup>1,2,3,4</sup>Teknik Informatika, Universitas Prima Indonesia, Indonesia

\*hendra\_pa1000@unprimdn.ac.id

## Abstract

*Manual detection of grape ripeness is inefficient and prone to subjective errors. This study developed a web-based automatic classification system using the YOLOv11 algorithm with the YOLO11s.pt model and the Roboflow platform. A deep learning approach was applied to automate the classification of grapes into four ripeness categories: unripe, semi-ripe, ripe, and rotten. The dataset used consisted of 897 images obtained directly from the vineyard, then expanded to 6,135 images through preprocessing and augmentation. The labeling process was carried out using Roboflow, and model training was carried out on Google Colab for 200 epochs. The training results showed high performance, with a recall value of 0.95, a precision of 0.98, and a mean Average Precision (mAP) of 0.84. The system was able to distinguish multi-class objects with an average detection time of 1,02 seconds per image, thus supporting semi real-time operations. However, the accuracy of the semi-ripe class classification is still a challenge due to visual similarities with other classes. This system has been integrated into a web application that displays classification results in semi real-time, and has the potential to be applied in a digital agricultural system. For further research, it is recommended to optimize the dataset, especially by adding the amount of training data on the rotten and half-ripe grape classes. In addition, the development of the application into a mobile application is recommended to increase accessibility and flexibility of use.*

**Keywords:** yolov11, roboflow, deep learning, fruit ripeness classification

## Abstrak

Deteksi tingkat kematangan buah anggur secara manual kurang efisien dan rentan terhadap kesalahan subjektif. Penelitian ini mengembangkan sistem klasifikasi otomatis berbasis web menggunakan algoritma YOLOv11 dengan model YOLO11s.pt dan platform Roboflow. Pendekatan deep learning diterapkan untuk mengotomatiskan klasifikasi buah anggur ke dalam empat kategori kematangan: mentah, setengah matang, matang, dan busuk. Dataset yang digunakan terdiri dari 897 citra yang diperoleh langsung dari kebun anggur, kemudian diperluas menjadi 6.135 citra melalui proses *preprocessing* dan *augmentasi*. Proses pelabelan dilakukan menggunakan Roboflow, dan pelatihan model dilaksanakan di Google Colab selama 200 *epoch*. Hasil pelatihan menunjukkan kinerja yang tinggi, dengan nilai *recall* sebesar 0,95, *precision* sebesar 0,98, dan *mean Average Precision* (mAP) mencapai 0,84. Sistem mampu membedakan objek multikelas dengan waktu deteksi rata-rata 1,02 detik per citra, sehingga mendukung pengoperasian secara semi real-time. Namun, akurasi klasifikasi kelas setengah matang masih menjadi tantangan karena kemiripan visual dengan kelas lainnya. Sistem ini telah diintegrasikan dalam bentuk aplikasi web yang menampilkan hasil klasifikasi secara semi real-time, dan memiliki potensi untuk diterapkan dalam sistem pertanian digital. Untuk penelitian selanjutnya, disarankan dilakukan optimalisasi dataset, khususnya dengan penambahan jumlah data pelatihan pada kelas anggur busuk dan setengah matang. Selain itu, pengembangan aplikasi ke dalam bentuk aplikasi mobile direkomendasikan guna meningkatkan aksesibilitas dan fleksibilitas pengguna.

**Kata kunci:** yolov11, roboflow, deep learning, klasifikasi kematangan buah

## 1. Pendahuluan

### 1.1. Latar Belakang

Indonesia merupakan negara beriklim tropis, yang mendukung pertumbuhan berbagai jenis buah lokal [1]. Meskipun anggur secara alami merupakan tanaman subtropis, penelitian menunjukkan bahwa

budidayanya telah berhasil dikembangkan di beberapa wilayah Indonesia dengan penyesuaian teknik pertanian, memungkinkan tanaman ini tumbuh dan berbuah optimal di lingkungan tropis [2] [3]. Buah mengandung berbagai macam nutrisi serta berperan penting untuk memberikan manfaat yang baik bagi

kesehatan [4]. Anggur tergolong buah berry yang memiliki kandungan kaya akan berbagai vitamin, serat, mineral, kalium, nutrisi serta senyawa aktif sebagai antioksidan yang dapat melindungi tubuh dari kerusakan akibat radikal bebas yang berperan dalam menjaga metabolisme tubuh, mencegah pembentukan sel kanker, mendukung kesehatan jantung dan dapat mengurangi peradangan [5] [6].

Anggur dapat hidup pada daratan rendah pada suhu 23 °C - 31 °C dengan rentang kelembapan udara berkisar 75-80% dan didukung pencahayaan sinar matahari untuk menyempurnakan proses fotosintesis dan intensitas penyiraman 50-80% sehingga dapat tumbuh dengan baik [7][8]. Buah anggur memiliki kemampuan untuk menghasilkan buah sepanjang tahun dengan frekuensi panen mencapai tiga kali dalam setahun[9] [10]. Waktu yang tepat untuk menanam anggur adalah pada akhir musim hujan memasuki awal musim kemarau, dengan maksimal 3-4 bulan masa pertumbuhan hingga mencapai hasil yang sempurna [11]. Pemilihan pupuk yang tepat merupakan hal yang sangat penting untuk menghasilkan kualitas buah anggur yang baik, dalam hal ini menyemprotkan cairan pestisida ke batang hingga buah anggur dapat mencegah munculnya jamur bertujuan untuk mendapatkan hasil pohon anggur yang sehat dan buah yang lebat [12] [13].

Penelitian ini hanya mencakup anggur merah keunguan. Anggur hijau dikecualikan karena memiliki ciri visual yang berbeda dan memerlukan penanganan klasifikasi tersendiri. Kematangan buah anggur dapat dilihat dari tekstur permukaan buah, warna hijau hingga merah keunguan menuju masa matang serta memiliki bentuk bulat berukuran kecil dengan permukaan halus [14]. Pada umumnya, kualitas buah anggur dapat dilihat dari kesegaran buah dimana hal ini dapat dilakukan dengan cara manual menggunakan indera penglihatan manusia [15].

Menentukan kualitas buah anggur secara manual tentunya memakan waktu dan tenaga manusia. Pada penelitian ini, peneliti mengembangkan sistem deteksi kualitas kesegaran buah yang akurat dan efisien berdasarkan tekstur permukaan kulit hingga warna pada buah menggunakan algoritma

YOLO (*You Only Look Once*) [16]. Algoritma YOLO digunakan untuk mendeteksi objek dan terbukti mencapai nilai akurasi yang cukup tinggi [17]. YOLOv11 merupakan versi terbaru dari algoritma YOLO dan bukan modifikasi langsung dari YOLOv8. Algoritma ini mampu meningkatkan kualitas dan memproses gambar dengan cepat dalam satu kali proses pemindaian guna mendeteksi objek dengan berbagai kondisi pencahayaan dan latar belakang yang berbeda [18].

Penggunaan YOLOv11 mengotomatisasi proses kematangan buah secara akurat dan hal ini menjadikan YOLOv11 mampu mengurangi potensi kesalahan dalam penilaian tingkat kematangan buah [19]. Teknologi YOLOv11 tidak hanya meningkatkan kecepatan deteksi, tetapi juga mendukung *fleksibilitas* dalam pengolahan data berkat arsitekturnya yang ringan dan efisien [20]. Relevansi pemanfaatan metode ini diperkuat oleh sejumlah penelitian terdahulu berdasarkan penelitian Irfandiana Nurhasanah menunjukkan bahwa metode CNN dengan arsitektur ResNet152v2 mampu mengklasifikasikan tingkat kematangan buah anggur dengan akurasi tinggi, yaitu 91,67% pada data pengujian, hal ini membuktikan bahwa pendekatan deep learning sangat efektif dalam mengenali tingkat kematangan buah [21].

Selain itu, menurut studi Wahyu Saputro dan Dyan Bagus Sumantri yang menggunakan algoritma K-Nearest Neighbor (KNN) dengan data augmentasi juga berhasil mencapai akurasi sebesar 80,98% dalam klasifikasi enam jenis anggur berdasarkan warna [22]. Meskipun demikian, pendekatan KNN cenderung kurang optimal dalam pengenalan objek kompleks dibanding metode deep learning seperti YOLOv11.

Sementara itu, berdasarkan Afriadi dan Agung Ramadhanu, menggunakan pendekatan *hybrid* PCA-KNN untuk mengklasifikasikan anggur dan pepaya dan berhasil mencapai akurasi 90%, namun jumlah data uji terbatas pada 10 citra [23]. Temuan lain didapat dari Sri Melisa et al juga menunjukkan bahwa metode KNN dapat digunakan untuk klasifikasi tingkat

kematangan anggur, namun efektivitasnya terbatas jika dibandingkan dengan YOLOv11 dalam hal generalisasi dan efisiensi [24]. Oleh karena itu, penggunaan YOLOv11 pada penelitian ini dinilai lebih unggul karena mampu mendeteksi objek multikelas dalam satu pemindaian secara cepat dan akurat, serta menunjukkan potensi besar sebagai solusi efektif terhadap permasalahan penilaian manual yang subjektif dan memakan waktu [25] [26].

Penelitian ini bertujuan untuk mengembangkan aplikasi berbasis web yang mampu mendeteksi tingkat kematangan buah anggur secara otomatis menggunakan algoritma YOLOv11. Selain itu, penelitian ini juga bertujuan untuk menganalisis berbagai faktor yang memengaruhi kematangan buah anggur serta meningkatkan kemampuan sistem dalam melakukan klasifikasi tingkat kematangan secara akurat, efisien sehingga dapat memberikan manfaat dalam proses pemanenan dan distribusi buah yang lebih efektif.

## 2. Metode Penelitian

### 2.1. Jenis Penelitian

Penelitian kuantitatif yang dilakukan pada penelitian ini bertujuan untuk mengklasifikasi dan mendeteksi tingkat kematangan buah secara objektif. Memanfaatkan pendekatan berbasis *deep learning* dengan fokus utama pada penggunaan algoritma YOLOv11 (*You Only Look Once version 11*) sebagai metode deteksi objek secara *semi real-time* dengan akurasi tinggi [27]. Data yang digunakan berupa citra buah anggur diolah untuk melatih model yang mampu secara otomatis mengidentifikasi tingkat kematangan buah mentah, setengah matang, matang dan busuk.

### 2.2. Alat dan Dataset

#### 2.2.1. Alat

Penelitian ini menggunakan beberapa alat yang berupa 1 unit laptop dengan *type* Asus TUF F15 FX506LH dengan prosesor *Intel Core I5* dan RAM 16 GB dan 1 unit laptop LENOVO V14-ADA dengan prosesor *AMD Athlon Gold 3150u with Radeon Graphics* dan RAM 4 GB.

#### 2.2.2. Dataset

*Dataset* yang digunakan dalam penelitian ini diperoleh dari Kebun Bayanaka yang berlokasi di Jalan Turi No. 71, Kelurahan Sudirejo, Kecamatan Medan Kota. Kebun Bayanaka dipilih berdasarkan karakteristik lahan dan tanaman anggur yang mendukung proses pengambilan data secara langsung di lingkungan nyata. Pengumpulan data dilakukan dengan memotret buah anggur dalam berbagai kondisi kematangan secara langsung, dan diproses serta dianotasi melalui *platform Roboflow*. Proses observasi dilakukan terhadap berbagai faktor, seperti pencahayaan alami, posisi tanaman, dan tekstur buah untuk memastikan keberagaman dalam dataset.

*Dataset* yang dikumpulkan berjumlah 897 gambar buah anggur asli yang terbagi atas 394 gambar buah anggur mentah, 178 gambar buah anggur setengah matang, 248 gambar buah anggur matang dan 77 gambar buah anggur busuk yang belum melalui proses pengolahan.

### 2.3. Metode

#### 2.3.1. Roboflow

*Roboflow platform* yang dirancang untuk membantu pengelolaan dataset dan berperan dalam tahap persiapan data sebelum proses pelatihan model. Dalam penelitian ini, data buah anggur diperoleh secara langsung melalui proses pengambilan gambar di kebun, kemudian diunggah ke *Roboflow* untuk dilakukan anotasi dan klasifikasi sesuai dengan empat kelas tingkat kematangan, yaitu anggur mentah, setengah matang, matang, dan busuk menggunakan *tool smart polygon (AI labeling)* dengan total data setelah dianotasi mencapai 2.395 anotasi. Dalam satu gambar buah anggur terdapat rata-rata 2,7 objek yang dianotasi.

*Dataset* kemudian dibagi menjadi tiga subset: data latih sebanyak 718 gambar (80%), data validasi sebanyak 107 gambar (12%), dan data uji sebanyak 72 gambar (8%). Pembagian data selengkapnya ditampilkan pada Tabel 1 berikut:

Tabel 1. Pembagian Data

Kelas	Train 80%	Valid 12%	Test 8%	Total
Anggur Mentah	823	147	89	1.059
Anggur Setengah Matang	280	48	19	347

Anggur Matang	626	102	70	798
Anggur Busuk	141	26	24	191
Jumlah Total	1.870	323	202	2.395

Pembagian *dataset* dilakukan untuk menjaga keseimbangan distribusi kelas pada tiap subset, guna mendukung proses pembelajaran model, penyetelan parameter, dan evaluasi performa model secara optimal serta mencegah bias. Data latih digunakan sebagai bahan utama pelatihan oleh sistem, data validasi untuk memantau kinerja dan menyesuaikan hiperparameter, sedangkan data uji berfungsi mengevaluasi performa akhir model setelah proses pelatihan untuk mencapai akurasi, presisi, *recall*, dan mAP.

Setelah proses anotasi selesai, dilakukan tahap *preprocessing* menggunakan berbagai fitur yang tersedia di *Roboflow* dengan melakukan normalisasi ukuran gambar menggunakan metode *stretching* untuk menyesuaikan dimensi semua gambar ke ukuran *input* tetap yang dibutuhkan oleh model YOLOv11s.pt yaitu resolusi 640×640 piksel. Selain itu, fitur *auto-orientation* juga digunakan untuk menyamakan orientasi gambar, serta penyesuaian nilai RGB agar berada dalam skala optimal untuk proses pelatihan. Terakhir, fitur *isolate object* digunakan untuk memisahkan objek anggur dari latar belakang, sehingga model dapat lebih fokus pada area penting dalam gambar dan meningkatkan akurasi deteksi.

Untuk mengatasi risiko *overfitting* dan meningkatkan keragaman data, dilakukan proses *augmentasi* melalui *Roboflow*. Teknik *augmentasi* yang diterapkan meliputi *flip horizontal* dan *vertikal* guna menghasilkan variasi sudut pandang objek, serta rotasi 90° baik searah maupun berlawanan arah jarum jam untuk memperluas distribusi posisi objek. Penyesuaian kecerahan dilakukan dalam rentang -15% hingga +15% guna mensimulasikan berbagai kondisi pencahayaan, sementara pengaturan eksposur berada antara -10% hingga +10% untuk memberikan variasi intensitas cahaya yang memengaruhi kontras dan ketajaman citra. Pengaturan kontras dan saturasi tidak diterapkan atau bernilai nol dalam *augmentasi* untuk menjaga keaslian warna buah anggur yang menjadi indikator utama dalam klasifikasi tingkat kematangan.

Perubahan pada kedua aspek ini dapat mengganggu representasi warna alami, sehingga berisiko menurunkan akurasi deteksi dan klasifikasi model. Selain itu, digunakan pula teknik *mosaic*, yaitu menggabungkan beberapa gambar dalam satu bingkai untuk memperkaya konteks spasial dan memperluas informasi visual. Seluruh langkah ini bertujuan untuk memperkuat kemampuan generalisasi model dalam mendeteksi buah anggur pada berbagai kondisi lingkungan. *Roboflow* berperan penting dalam tahap *preprocessing* sebelum model dilatih menggunakan YOLOv11 di *Google Colab*[28].

Setelah proses *preprocessing* dan *augmentasi* yang telah dilakukan, jumlah gambar total otomatis meningkat menjadi 6.135 gambar. Pembagian data setelah melakukan *preprocessing* dan *augmentasi* selengkapnya ditampilkan pada Tabel 2 berikut:

Tabel 2. Hasil Gambar Setelah Preprocessing Dan Augmentasi

<i>Split Dataset</i>	Jumlah Gambar	Persentase
<i>Train</i>	5610	91%
Validasi	323	5%
<i>Test</i>	202	3%
Total	6135	100%

### 2.3.2. YOLOv11

YOLOv11 merupakan versi lanjutan dari algoritma YOLO (*You Only Look Once*), dirancang untuk mendeteksi objek dalam gambar secara semi *real-time* dengan tingkat akurasi dan kecepatan yang tinggi. Pembaruan signifikan pada YOLOv11 terletak pada optimalisasi struktur jaringan dan mekanisme pelatihan yang lebih efisien, sehingga memungkinkan deteksi yang lebih cepat tanpa mengorbankan akurasi.

Dibandingkan dengan YOLOv8, YOLOv11 menawarkan keunggulan dalam hal kecepatan inferensi, efisiensi memori, serta peningkatan akurasi pada objek dengan ukuran kecil dan kompleksitas tinggi. Selain itu, model ini lebih stabil dalam proses pelatihan dan memiliki kemampuan generalisasi yang lebih baik terhadap data yang bervariasi.

#### 1. Akurasi (*Accuracy*)

Mengukur rasio prediksi benar atau *true positive* (TP) dari keseluruhan data prediksi salah atau *true negative* (TN), Jumlah kasus yang salah atau *false positive* (FP) dalam mencapai akurasi tinggi sebagai rasio prediksi benar atau *true positive* (TP) terhadap total jumlah prediksi.

$$Akurasi = \frac{TP + TN}{TP + TN + FP + FN}$$

## 2. Precision (Presisi)

Mengukur rasio prediksi positif atau *true positive* (TP) dari total model dan diambil dari seluruh prediksi positif untuk mengurangi kesalahan positif atau *false positive* (FP) dimana semakin tinggi *presicion* maka semakin sedikit kesalahan positif atau *false positive* (FP) dalam deteksi objek.

$$Precision = \frac{TP}{TP + FP}$$

## 3. Recall (Daya Ingat atau Sensitivitas)

Mengukur rasio prediksi positif atau *true positive* (TP) terdeteksi oleh model agar meminimalkan kesalahan negative atau *false negative* (FN). Semakin tinggi *recall*, semakin sedikit objek yang terlewat oleh model.

$$Recall = \frac{TP}{TP + FN}$$

## 4. Mean Average Precision (mAP)

Nilai rata-rata antara *precision* dan *recall* untuk menilai performa model (*C*) dalam mendeteksi objek *Average Precision* pada kelas ke - *c* (*AP<sub>c</sub>*) dengan benar.

$$Mean = mAP = \frac{1}{C} \sum_{c=1}^C AP_c$$

### 2.3.3. Google Colab

Setelah mengumpulkan data dari kebun anggur secara langsung, dataset diolah menggunakan *Roboflow*, lalu model YOLOv11 dilatih dan diimplementasikan di *Google Colab*. Platform berbasis *cloud* ini mendukung pemrosesan berkecepatan tinggi yang menyerupai *Jupyter notebook*. *Google Colab* memungkinkan untuk menjalankan eksperimen, optimasi model, serta mengevaluasi hasil deteksi dengan lebih *fleksibel* dan efisien.

### 2.3.4 Visual Studio Code

Perancangan aplikasi pendeteksian kematangan buah anggur (GRAPORA)

dilakukan dengan pendekatan *client-server* yang diimplementasikan melalui *Visual Studio Code*. Proses perancangan mencakup penyusunan alur sistem, arsitektur komponen, serta implementasi teknis berbasis web. Diagram alur sistem menggambarkan urutan proses dari unggahan gambar oleh pengguna hingga penyajian hasil deteksi kematangan buah anggur oleh sistem.

Sistem terdiri dari tiga komponen utama: *frontend*, *backend*, dan model deteksi. *Frontend* dibangun dengan HTML, CSS, dan JavaScript sebagai antarmuka yang memungkinkan pengguna mengunggah gambar, melihat hasil deteksi dan *persentase* kematangan anggur, meninjau riwayat deteksi, serta mengakses informasi terkait *Machine Learning*, *Roboflow*, dan YOLO. *Backend* menggunakan bahasa Python dengan *framework Flask* untuk memproses unggahan, menjalankan model deteksi dengan format *.onnx*, serta mengirimkan hasil ke *frontend* dan menyimpannya dalam file *history.json*. deteksi menggunakan YOLOv11 agar mampu mengklasifikasi tingkat kematangan anggur.

Implementasi sistem memanfaatkan kombinasi teknologi, yakni HTML5, CSS3, dan JavaScript untuk *frontend*, serta Python dan *Flask* pada sisi *backend*. Model YOLOv11 dijalankan melalui *ONNX Runtime*, sementara pelatihan model dilakukan di *Google Colab* dengan dukungan anotasi dari *Roboflow*. Aplikasi ini memiliki fitur utama seperti deteksi gambar otomatis, riwayat deteksi, penjelasan konsep teknologi, serta tampilan yang modern dan responsif. Seluruh elemen ini dirancang untuk menunjang tujuan utama aplikasi dalam mendeteksi kematangan buah anggur secara efektif dan akurat.

## 3. Hasil Penelitian

### 3.1. Training Model YOLOv11 Menggunakan Google Colab

Proses Pemodelan Data Model YOLO (*You Only Look Once*) diimplementasi pada platform *Google Colab* dengan memanfaatkan sumber daya komputasi berbasis GPU A100. Proses pemodelan diawali dengan konfigurasi pengembangan menggunakan *ultralitics 8.3.40 python-*

3.11.12 *torch* 2.6.0+cu124 CUDA:0 (NVIDIA A100-SXM4-40GB, 40507MiB yang kompatibel dengan arsitektur YOLOv11s.pt. Dataset hasil *preprocessing* diimpor dalam format YOLOv11 melalui *Roboflow*. Pelatihan model dilakukan selama 1 jam 41 menit dengan 200 *epoch* menggunakan 897 gambar dengan hasil *summary (fused)*: 238 *layers*, parameter 9,414,348, 0 *gradients*, 21.3 GFLOPs dan last.pt, 19.2MB. Dengan melalui *dashboard Weights* yang terintegrasi dengan *Colab notebook* disimpan dalam format .onnx mencakup *tracking precision*, *recall*, dan mAP berdasarkan nilai *training*, *validation loss* dan *metrics Plot*. Hasil pengujian dapat di ketahui selengkapnya pada Gambar 1 berikut.

```
200 epochs completed in 1.684 hours.
Optimizer stripped from /content/drive/myDrive/yolov11_training_result/train_yolov11/weights/best.pt, 19.2MB
Optimizer stripped from /content/drive/myDrive/yolov11_training_result/train_yolov11/weights/best.pt, 19.2MB

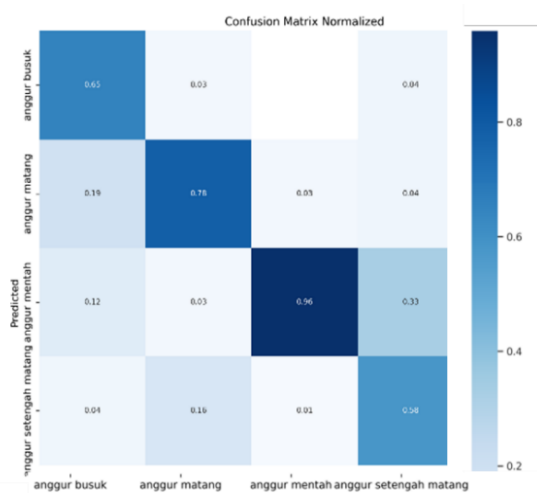
Validating /content/drive/myDrive/yolov11_training_result/train_yolov11/weights/best.pt...
Ultralytics 8.3.48 Python-3.11.12 torch-2.6.0+cu124 CUDA:0 (NVIDIA A100-SXM4-40GB, 40507MiB)
YOLOv11 summary (fused): 238 layers, 9,414,348 parameters, 0 gradients, 21.3 GFLOPs

Class Images Instances  mAP50  mAP50-95  mAP50-95 11/11 [00:02:00:00]
-----
all          323      323      0.769    0.768    0.842    0.842
anggur busuk 26       26       0.796    0.731    0.807    0.807
anggur matang 102      102      0.881    0.798    0.929    0.929
anggur mentah 147      147      0.858    0.952    0.975    0.972
anggur setengah matang 48       48       0.599    0.583    0.658    0.658

Speed: 0.1ms preprocess, 0.0ms inference, 0.0ms loss, 1.1ms postprocess per image
```

Gambar 1. Pengujian Yolo Menggunakan Google Colab

Hasil Analisis Model *confusion matrix* dapat di lihat pada Gambar 2 yang menunjukkan performa klasifikasi model yang cukup baik. Kelas anggur mentah menunjukkan tingkat akurasi tertinggi dengan 141 prediksi benar, diikuti oleh kelas anggur matang sebanyak 80 prediksi benar dan kelas anggur busuk sebanyak 17 prediksi benar.

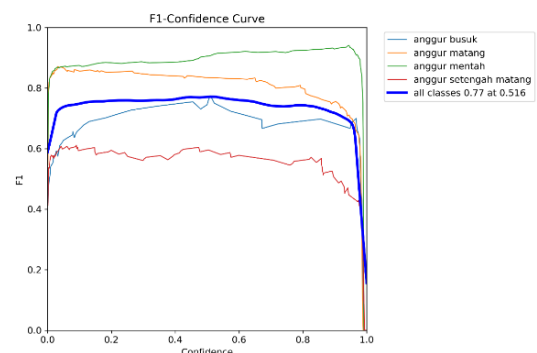


Gambar 2. Confusion Matrix

Sementara itu, kelas anggur setengah matang hanya berhasil dikenali sebanyak 28 kali

prediksi benar, dengan kesalahan klasifikasi terbesar ke kelas matang sebanyak 16 prediksi benar. Kesalahan juga ditemukan antar kelas lain, terutama akibat kemiripan fitur visual. Secara umum, model mampu membedakan sebagian besar kelas, namun masih kurang optimal dalam mengidentifikasi kelas setengah matang. Hal ini dapat diperbaiki melalui penambahan data, *augmentasi*, atau penyempurnaan arsitektur model.

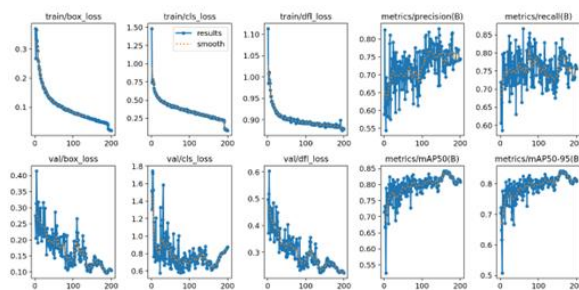
Kurva F1 terhadap *confidence* digunakan untuk menilai kemampuan model dalam membedakan empat kelas kematangan anggur. Kurva merepresentasikan keseimbangan antara *precision* dan *recall* pada berbagai tingkat *confidence*. Hasilnya, kelas anggur mentah menunjukkan F1 tertinggi dan paling stabil mendekati 0,96. Sedangkan kelas setengah matang memiliki performa terendah dengan F1 sekitar 0,58. Nilai F1 rata-rata sebesar 0,77 dicapai pada *confidence* 0,51, yang menjadi titik optimal dalam menghasilkan prediksi seimbang antara kesalahan *positif* dan *negatif*. Kurva selengkapnya dapat di lihat pada Gambar 3 berikut.



Gambar 3. F1 Confidence Curve

Pelatihan model menunjukkan *tren* penurunan yang konsisten pada nilai *box loss*, *classification loss*, dan *distribution focal loss*, baik pada data latih maupun validasi. Penurunan nilai loss menunjukkan bahwa model mengalami proses pembelajaran yang efektif dengan kemampuan meminimalkan kesalahan prediksi. Secara keseluruhan, model mencapai tingkat akurasi yang tinggi yakni berada pada rentang 92,9% hingga 97,5%. Meski terdapat fluktuasi kecil pada *validation loss*, *tren* umumnya tetap menurun, menandakan kemampuan generalisasi terhadap data baru.

Dari sisi evaluasi, nilai *precision* dan *recall* sebesar 0,77 terus meningkat seiring jumlah *epoch*, menunjukkan peningkatan akurasi klasifikasi. Metrik mAP50 dan mAP50-95 juga naik signifikan hingga di atas 0,84. Sistem menunjukkan performa tinggi dalam membedakan objek multikelas dengan waktu deteksi rata-rata 1,02 detik menandakan performa deteksi yang baik dalam berbagai skenario *bounding box*. Namun, potensi *overfitting* tetap perlu diwaspadai. Secara keseluruhan, model dinilai telah mencapai performa optimal dalam klasifikasi dan deteksi multikelas. Untuk melihat Hasil visualisasi *training* dan evaluasi model dapat diketahui pada Gambar 4 berikut.

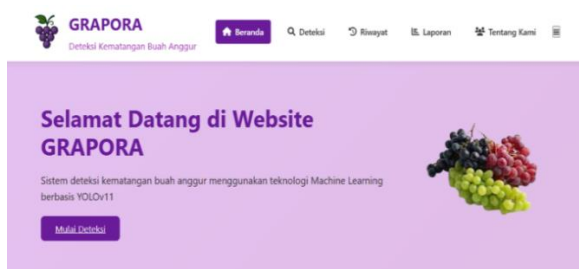


Gambar 4. Hasil Visualisasi Training Dan Evaluasi Model

## 3.2. Tampilan Website

### 3.2.1 Beranda

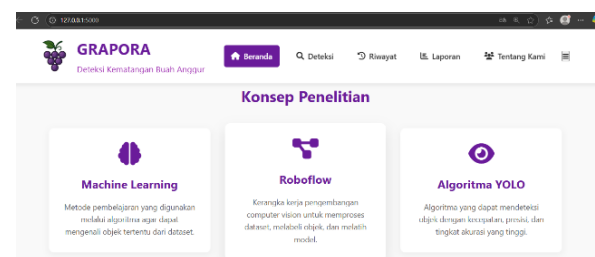
Berdasarkan gambar 5 dimana beranda, menampilkan ringkasan fungsi utama dari sistem deteksi kematangan buah anggur, disertai penjelasan singkat mengenai tujuan dan manfaat aplikasi. Pada bagian ini, web menampilkan gambaran umum tentang pentingnya klasifikasi kematangan anggur dalam industri pertanian serta motivasi pengembangan sistem berbasis kecerdasan buatan.



Gambar 5. Beranda Website

Tampilan website anggur ditampilkan pada Gambar 6 yang memuat konsep

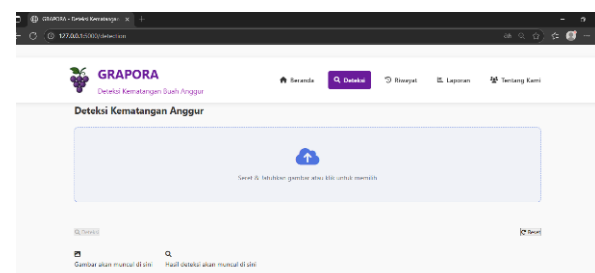
*Machine Learning* yang digunakan dalam proses klasifikasi tingkat kematangan buah anggur. Data citra dilabeli menggunakan *platform Roboflow* untuk mengelompokkan ke dalam beberapa kelas, yaitu anggur busuk, matang, mentah, dan setengah matang. Pemilihan YOLO (*You Only Look Once*) sebagai algoritma deteksi objek didasarkan pada performanya yang unggul dalam mendeteksi, di antara varian model yang tersedia dalam YOLOv11 yaitu (Yolo11n.pt, Yolo11s.pt, Yolo11m.pt, Yolo11l.pt dan Yolo11x.pt), maka model Yolo11s.pt dipilih karena menawarkan keseimbangan yang optimal antara akurasi dan efisiensi komputasi. Model Yolo11s.pt dilatih dan diuji melalui Google Colab dengan pemanfaatan GPU untuk mempercepat proses komputasi. Hasil pelatihan dan evaluasi model ditampilkan pada antarmuka web sebagai bagian dari visualisasi proses dan performa sistem.



Gambar 6. Beranda Konsep *Machine Learning*

### 3.2.2 Halaman Proses Deteksi Anggur

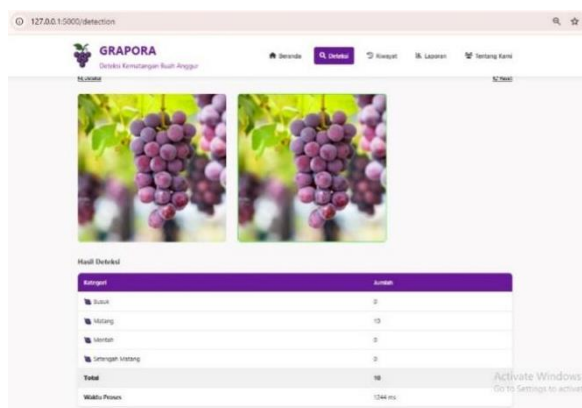
Halaman proses deteksi pada Gambar 7, menyediakan area unggah citra yang memungkinkan pengguna dalam memilih *file* dengan cara mengklik atau menyeret gambar ke dalam area yang tersedia. Setelah gambar diunggah, model akan secara otomatis mengenali dan mengklasifikasikan tingkat kematangan buah anggur.



Gambar 7. Proses Deteksi dan Klasifikasi

### 3.2.3 Analisis Hasil Deteksi

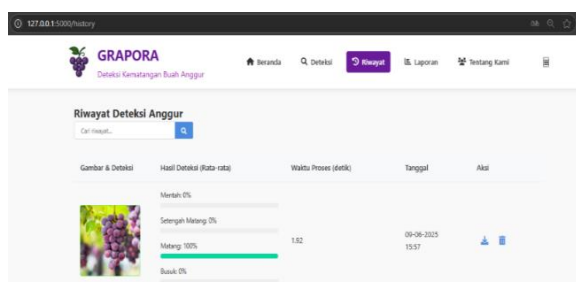
Bagian sistem yang menampilkan hasil klasifikasi tingkat kematangan buah anggur berdasarkan citra gambar yang diunggah. Proses deteksi dilakukan secara otomatis menggunakan model yang telah dilatih sebelumnya, dengan hasil klasifikasi ditampilkan dalam kategori sesuai tingkat kematangan. Model mendeteksi objek dengan menandai tiap buah menggunakan *bounding box* disertai label dan *presentase* kematangan dari buah anggur, sehingga mampu mengklasifikasikan buah anggur secara akurat meskipun terdapat variasi pencahayaan dan latar belakang, serta mempermudah pengguna memahami hasil deteksi secara mudah. Analisis deteksi dapat diketahui berdasarkan Gambar 8 berikut.



Gambar 8. Analisis Hasil Deteksi Anggur

### 3.2.4 Riwayat Deteksi

Pada Gambar 9 dapat diketahui bahwa, dapat menampilkan riwayat hasil deteksi tingkat kematangan buah anggur, disertai informasi hasil klasifikasi, waktu proses, serta tanggal dan waktu pelaksanaan deteksi. Untuk memantau performa sistem dan menyimpan hasil deteksi sebelumnya dan meningkatkan transparansi dan kemudahan pelacakan.

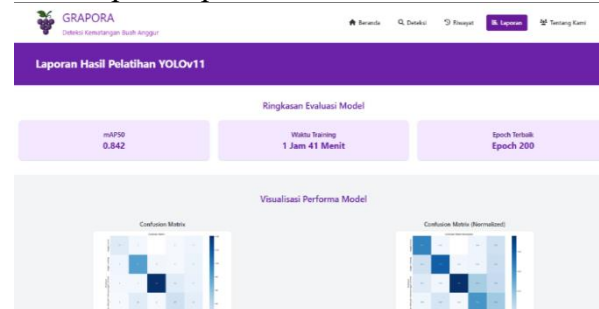


Gambar 9. Riwayat Deteksi Anggur

### 3.2.5 Laporan Uji Epoch dan Pelatihan

### Model

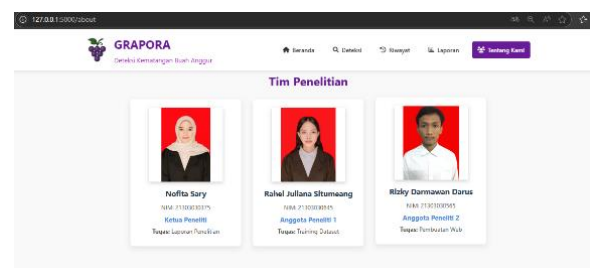
Hasil dari Gambar 10 diketahui dapat menampilkan hasil uji coba yang telah dilakukan selama proses pengembangan sistem, pelatihan model mengenai performa model. Seluruh laporan hasil pengujian evaluasi model, waktu pemrosesan ditampilkan dalam visualisasi grafik performa selama proses pelatihan.



Gambar 10. Laporan Uji Epoch dan Pelatihan Model Yolo V11

### 3.2.6 Tentang Kami

Memuat informasi mengenai latar belakang tim, peran masing-masing anggota tim dalam proses perancangan, pengembangan serta penyusunan laporan. Informasi dapat dilihat pada Gambar 11 berikut.



Gambar 11. Tentang Kami

## 4. Kesimpulan

Sistem deteksi menggunakan YOLOv11 dan *Roboflow* dengan berbasis web berhasil dikembangkan untuk klasifikasi kematangan buah anggur dengan akurasi tinggi (mAP 0.84) dan kecepatan 1,02 detik/citra. Sebanyak 897 citra anggur yang terbagi ke dalam beberapa kelas telah digunakan untuk pelatihan menggunakan model YOLO11s.pt selama 200 *epoch* pada platform *Google Colab*. Hasil evaluasi menunjukkan nilai performa sebesar 0.84, sehingga penambahan *epoch* tidak diperlukan lagi.

Namun, diperlukan kemampuan model dalam membedakan kelas anggur mentah dan setengah matang yang memiliki kemiripan visual, terutama untuk pemisahan antara anggur mentah dan anggur matang. Selain itu, kelas anggur busuk dan setengah matang juga masih menunjukkan ruang untuk peningkatan akurasi dalam proses klasifikasi dan diperlukan peningkatan jumlah dataset busuk dan setengah matang untuk memperoleh nilai yang lebih baik. Penelitian ini memiliki keterbatasan masih memakai *website* dalam mengklasifikasi dan dilakukan secara *semi real-time*.

Dari sisi keterbaruan, penelitian ini telah menjelaskan secara komprehensif bahwa pemanfaatan algoritma YOLOv11 memberikan keunggulan signifikan dibanding metode sebelumnya seperti KNN, PCA-KNN, maupun CNN, baik dari sisi kecepatan, akurasi, maupun kemampuan deteksi multikelas dalam satu proses pemindaian secara otomatis.

## 5. Saran

Penelitian selanjutnya disarankan untuk mengoptimalkan hasil dengan meningkatkan kualitas dataset, khususnya melalui penambahan jumlah data pelatihan pada kelas anggur busuk dan setengah matang serta penerapan teknik augmentasi citra guna memperkaya variasi visual. Upaya ini bertujuan meningkatkan kemampuan model dalam membedakan kelas dengan karakteristik serupa khususnya pada kelas matang dan setengah matang. Selain itu, peningkatan performa model sebaiknya difokuskan pada pengembangan arsitektur jaringan, bukan sekadar penambahan *epoch* pelatihan. Selain itu, perlu dipertimbangkan pengembangan aplikasi berbasis mobile untuk meningkatkan aksesibilitas dan fleksibilitas pengguna. Penerapan sistem deteksi secara real-time dan optimalisasi lanjutan terhadap teknologi YOLO dan Roboflow juga direkomendasikan guna meningkatkan akurasi dan efisiensi sistem secara berkelanjutan, sebagaimana telah dijelaskan dalam bagian keterbaruan terkait efektivitas pendekatan YOLOv11 dibanding metode lain.

Untuk meningkatkan kinerja sistem deteksi, disarankan untuk menambahkan jumlah data pelatihan terutama pada kelas setengah matang dan busuk. Penelitian selanjutnya dapat mengeksplorasi pengembangan arsitektur model serta teknik augmentasi lanjutan agar dapat meningkatkan generalisasi model pada citra baru. Selain itu, pengembangan aplikasi ke platform mobile dan penerapan deteksi secara real-time sangat direkomendasikan guna meningkatkan fleksibilitas pengguna dan penerapan lapangan secara langsung.

## 6. Daftar Pustaka

- [1] S. Kamila, W. D. Widodo, E. Santosa, and M. R. Suhartanto, "Flowering and fruiting phenology in two varieties of grapes (*Vitis vinifera*) in tropical regions, Indonesia," *Biodiversitas*, vol. 25, no. 11, pp. 4593–4602, Nov. 2024, doi: 10.13057/biodiv/d251158.
- [2] J. Homepage *et al.*, "BATIK: Jurnal Pengembangan dan Pengabdian Masyarakat Multikultural Making Biochar and Organic Fertilizer for Grape Cultivation at KWT Mentari, Pontianak City," *institut riset dan publikasi indonesia*, vol. 1, pp. 131–137, Dec. 2023.
- [3] N. Fadilah, I. Dwiyantri, N. Fauziah, and Y. Yusalina, "Model Pengembangan Anggur Bogor Berbasis Local Knowledge dengan Pendekatan Agribisnis di Ciptagelar," *Jurnal Ilmu Pertanian Indonesia*, vol. 27, no. 1, pp. 48–53, Jan. 2022, doi: 10.18343/jipi.27.1.48.
- [4] M. Del Río-Celestino and R. Font, "The health benefits of fruits and vegetables," 2020, *MDPI Multidisciplinary Digital Publishing Institute*. doi: 10.3390/foods9030369.
- [5] H. Wang, "Medical Benefits and Polymer Applications of Grapes," Mar. 01, 2025, *Multidisciplinary Digital Publishing Institute (MDPI)*. doi: 10.3390/polym17060750.
- [6] D. D. Zhou *et al.*, "Bioactive Compounds, Health Benefits and Food Applications of Grape," Sep. 01, 2022, *MDPI*. doi: 10.3390/foods11182755.
- [7] Luh Putu Yuni Widyastuti and Ni Kadek Ema Sustia Dewi, "Productivity and Brix value of Green Grapes (*Vitis vinifera* L var. Muscat Saint Vallier) at Different Location and Pruning Time in Buleleng

- Bali,” *SEAS (Sustainable Environment Agricultural Science)*, vol. 7, no. 2, pp. 139–144, Oct. 2023, doi: 10.22225/seas.7.2.8222.139-144.
- [8] A. Khadatkar *et al.*, “A comprehensive review on grapes (*Vitis* spp.) cultivation and its crop management,” *Discover Agriculture*, vol. 3, no. 1, Jan. 2025, doi: 10.1007/s44279-025-00162-2.
- [9] “Kajian Penetapan Harga Jual Bibit, Buah Anggur Pada Komunitas Petani”.
- [10] T. Karakteristik Sari Buah Anggur Berbulir *et al.*, “(Online) I Made Dwi Wikananta dkk.”
- [11] A. Putri Wahyuzan, D. Eldora Purba, And M. Rahma Azzahra, “Analisis Perlakuan Akuntansi Agrikultur Pada Budidaya Perkebunan Anggur,” 2024, [Online]. Available: <https://journal.maranatha.edu/index.php/jafta>
- [12] Y. S. Wulandari *et al.*, “Bauran Pemasaran (Marketing Mix) Bibit Anggur (*Vitis Vinifera*) Pada Usaha Kebun Anggur Pulo Gebang Marketing Mix of Grape Seeds (*Vitis Vinifera*) in Pulo Gebang Vineyard Business”.
- [13] J. Pengabdian *et al.*, “Menggiatkan komunitas tanaman anggur menggunakan Pupuk Organik bersama Universitas Pelita Bangsa dengan Pencinta Tanaman Anggur di Cikarang”, [Online]. Available: <https://jurnal.alungcipta.com/index.php/jpmas/index>
- [14] J. Harnaranda and dan Agung Ramadhanu, “2024, Pages 5967-5974(online) Journal of Education Research,” *Journal of Education Research*, vol. 5, no. 4.
- [15] D. Liandaputra and A. Zahra, “Klasifikasi Tingkat Kematangan Buah Nanas Menggunakan Metode Deep Learning,” *G-Tech: Jurnal Teknologi Terapan*, vol. 8, no. 2, pp. 1091–1103, Apr. 2024, doi: 10.33379/gtech.v8i2.4122.
- [16] F. Gusnanto, N. Rahaningsih, and R. D. Dana, “Optimasi Model Klasifikasi Tingkat Kematangan Buah Mangga Dengan Metode YOLO11,” 2025. [Online]. Available: <https://www.kaggle.com/datasets/mutiurrehman/ripen>
- [17] R. Hesanda, “Implementasi Model YOLO V5 Untuk Deteksi Korek Api Dalam Keamanan Penerbangan,” *Jurnal Informatika dan Teknik Elektro Terapan*, vol. 13, no. 1, Jan. 2025, doi: 10.23960/jitet.v13i1.5553.
- [18] F. Gusnanto, N. Rahaningsih, and R. D. Dana, “Optimasi Model Klasifikasi Tingkat Kematangan Buah Mangga Dengan Metode YOLO11,” 2025. [Online]. Available: <https://www.kaggle.com/datasets/mutiurrehman/ripen>
- [19] H. Z. Amrulloh and F. A. N. Muhammad, “Deteksi Rambutan Matang dan Busuk Menggunakan Algoritma YOLOv9,” *JIKO (Jurnal Informatika dan Komputer)*, vol. 9, no. 1, p. 53, Feb. 2025, doi: 10.26798/jiko.v9i1.1382.
- [20] R. Agil, Y. Arjun, and E. P. Silmina, “Deteksi Bahan Pangan Tinggi Protein Menggunakan Model You Only Look Once (YOLO),” *Technology and Science (BITS)*, vol. 6, no. 4, 2025, doi: 10.47065/bits.v6i4.6889.
- [21] Nurhasanah Irfadiana, “Irfadiana Nurhasanah D121 18 1501 Program Studi Sarjana Teknik Informatika Fakultas Teknik Universitas Hasanuddin Gowa 2023,” gowa, 2023.
- [22] W. Saputro, D. B. Sumantri, S. Tinggi, I. Komputer, and C. Karya Informatika, “Implementasi Citra Digital Dalam Klasifikasi Jenis Buah Anggur Dengan Algoritma K-Nearest Neighbors (Knn) Dan Data Augmentasi Digital Image Implementation In Grape Classification With K-Nearest Neighbors (Knn) Algorithm And Augmentation Data,” *Journal of Information Technology and Computer Science (INTECOMS)*, vol. 5, no. 2, 2022.
- [23] J. Harnaranda and dan Agung Ramadhanu, “2024, Pages 5967-5974(online) Journal of Education Research,” *Journal of Education Research*, vol. 5, no. 4, 2024.
- [24] S. Melisa and A. Fauzi, “Penerapan Machine Learning Untuk Klasifikasi Tingkat Kematangan Buah Anggur (*Vitis*) Dengan Metode K-Nearest Neighbor,” 2022.
- [25] Z. Tian, F. Yang, L. Yang, Y. Wu, J. Chen, and P. Qian, “An Optimized YOLOv11 Framework for the Efficient Multi-Category Defect Detection of Concrete Surface,” *Sensors*, vol. 25, no. 5, Mar. 2025, doi: 10.3390/s25051291.
- [26] R. Sapkota, Z. Meng, M. Churuvija, X. Du, Z. Ma, and M. Karkee, “Comprehensive Performance Evaluation of YOLOv12, YOLO11, YOLOv10, YOLOv9 and YOLOv8 on Detecting and Counting Fruitlet in Complex Orchard

- Environments,” Feb. 2025, [Online]. Available:  
<http://arxiv.org/abs/2407.12040>
- [27] M. A. R. Alif, “YOLOv11 for Vehicle Detection: Advancements, Performance, and Applications in Intelligent Transportation Systems,” Oct. 2024, [Online]. Available:  
<http://arxiv.org/abs/2410.22898>
- [28] V. V. Kukartsev, R. A. Ageev, A. S. Borodulin, A. P. Gantimurov, and I. I. Kleshko, “Deep Learning for Object Detection in Images Development and Evaluation of the YOLOv8 Model Using Ultralytics and Roboflow Libraries,” in *Lecture Notes in Networks and Systems*, Springer Science and Business Media Deutschland GmbH, 2024, pp. 629–637. doi: 10.1007/978-3-031-70285-3\_48.